

最小二乘辨识

- 最小二乘辨识的基本概念
- 最小二乘问题的提法
- 最小二乘问题的解
- 最小二乘估计的可辨识性

1 最小二乘法的基本概念

● 最小二乘原理

定义： 设一个随机序列 $\{z(k), k \in (1, 2, \dots, L)\}$ 的均值是参数 θ 的线性函数

$$E\{z(k)\} = h^T(k)\theta$$

其中 $h(k)$ 是可测的数据向量，那么利用随机序列的一个实现，使准则函数

$$J(\theta) = \sum_{k=1}^L [z(k) - h^T(k)\theta]^2$$

达到极小的参数估计值 $\hat{\theta}$ 称作 θ 的最小二乘估计。

1 最小二乘法的基本概念

- 最小二乘原理表明，未知参数估计问题，就是求参数估计值，使序列的估计值尽可能地接近实际序列，两者的接近程度用实际序列与序列估计值之差的平方和来度量。
- 如果系统的输入输出关系可以描述成如下的最小二乘格式

$$z(k) = \mathbf{h}^T(k)\boldsymbol{\theta} + n(k)$$

式中 $z(k)$ 为模型输出变量， $\mathbf{h}(k)$ 为输入数据向量， $\boldsymbol{\theta}$ 为模型参数向量， $n(k)$ 为零均值随机噪声。

1 最小二乘法的基本概念

●为了求模型的参数估计值，可以利用上述最小二乘原理。根据观测到的已知数据序列 $\{z(k)\}$ 和 $\{h(k)\}$ ，极小化下列准则函数

$$J(\theta) = \sum_{k=1}^L [z(k) - h^T(k)\theta]^2$$

即可求得模型参数的最小二乘估计值 $\hat{\theta}$ 。

● 最小二乘估计值应在观测值与估计值之累次误差的平方和达到最小值处，所得到的模型输出能最好地逼近实际系统的输出。

2 最小二乘问题的提法

(1) 考虑模型

$$A(z^{-1})z(k) = B(z^{-1})u(k) + n(k)$$

式中 $u(k)$ 和 $z(k)$ 分别为模型输入和输出变量, $n(k)$ 是均值为零、方差为 σ_n^2 的随机噪声, $A(z^{-1})$ 和 $B(z^{-1})$ 为迟延算子多项式, 写成

$$\begin{cases} A(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \cdots + a_{n_a} z^{-n_a} \\ B(z^{-1}) = b_1 z^{-1} + b_2 z^{-2} + \cdots + b_{n_b} z^{-n_b} \end{cases}$$

2 最小二乘问题的提法

(2) 假定模型阶次 n_a 和 n_b 为已知, 且有 $n_a \geq n_b$, 也可设 $n_a = n_b = n$, 并定义

$$\begin{cases} \mathbf{h}(k) = [-z(k-1), \dots, -z(k-n_a), u(k-1), \dots, u(k-n_b)]^\tau \\ \boldsymbol{\theta} = [a_1, a_2, \dots, a_{n_a}, b_1, b_2, \dots, b_{n_b}]^\tau \end{cases}$$

2 最小二乘问题的提法

(3) 将模型写成最小二乘格式

$$z(k) = \mathbf{h}^T(k) \boldsymbol{\theta} + n(k)$$

对于 (L 为数据长度), 可以构成如下线性方程组

$$\mathbf{z}_L = \mathbf{H}_L \boldsymbol{\theta} + \mathbf{n}_L$$

式中

$$\left\{ \begin{array}{l} \mathbf{z}_L = [z(1), z(2), \dots, z(L)]^T \\ \mathbf{H}_L = \begin{bmatrix} \mathbf{h}^T(1) \\ \mathbf{h}^T(2) \\ \vdots \\ \mathbf{h}^T(L) \end{bmatrix} = \begin{bmatrix} -z(0) & \cdots & -z(1-n_a) & u(0) & \cdots & u(1-n_b) \\ -z(1) & \cdots & -z(2-n_a) & u(1) & \cdots & u(2-n_b) \\ \vdots & \cdots & \vdots & \vdots & \cdots & \vdots \\ -z(L-1) & \cdots & -z(L-n_a) & u(L-1) & \cdots & u(L-n_b) \end{bmatrix} \\ \mathbf{n}_L = [n(1), n(2), \dots, n(L)]^T \end{array} \right.$$

2 最小二乘问题的提法

(4) 噪声的统计性质

$$\mathbf{E}\{\mathbf{n}_L\} = 0, \quad \mathbf{cov}\{\mathbf{n}_L\} = \mathbf{E}\{\mathbf{n}_L \mathbf{n}_L^\tau\} = \boldsymbol{\Sigma}_n$$

(5) 噪声与输入不相关

$$\mathbf{E}\{n(k)u(k-l)\} = 0, \quad \forall k, l$$

(6) 数据长度 L 充分大

3 最小二乘问题的解

- 考虑模型

$$A(z^{-1})z(k) = B(z^{-1})u(k) + n(k)$$

- 准则函数取

$$J(\boldsymbol{\theta}) = \sum_{k=1}^L \Lambda(k) [z(k) - \mathbf{h}^T(k)\boldsymbol{\theta}]^2$$

其中 $\Lambda(k)$ 为加权因子，对所有的 k , $\Lambda(k)$ 都必须大于零。

- 准则函数又可写成

$$J(\boldsymbol{\theta}) = (\mathbf{z}_L - \mathbf{H}_L \boldsymbol{\theta})^T \boldsymbol{\Lambda}_L (\mathbf{z}_L - \mathbf{H}_L \boldsymbol{\theta})$$

3 最小二乘问题的解

式中 Λ_L 为加权矩阵，它是正定的对角阵，由加权因子 Λ_k 构成

$$\Lambda(L) = \begin{bmatrix} \Lambda(1) & 0 & \cdots & 0 \\ 0 & \Lambda(2) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \Lambda(L) \end{bmatrix}$$

该准则函数 $J(\theta)$ 可用于衡量模型输出与实际系统输出的接近情况。极小化这个准则函数，即可求得模型的参数估计值，使模型的输出能最好地预报系统的输出。

3 最小二乘问题的解

设 $\hat{\boldsymbol{\theta}}_{\text{WLS}}$ 使得 $J(\boldsymbol{\theta})|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} = \min$, 则有

$$\left. \frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} = \frac{\partial}{\partial \boldsymbol{\theta}} (\mathbf{z}_L - \mathbf{H}_L \boldsymbol{\theta})^\tau \boldsymbol{\Lambda}_L (\mathbf{z}_L - \mathbf{H}_L \boldsymbol{\theta}) \Big|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} = \mathbf{0}^\tau$$

展开, 并运用如下两个向量微分公式:

$$\begin{cases} \frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^\tau \mathbf{x}) = \mathbf{a}^\tau \\ \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\tau \mathbf{A} \mathbf{x}) = 2\mathbf{x}^\tau \mathbf{A}, \quad \mathbf{A} \text{ 为对称阵} \end{cases}$$

得

$$(\mathbf{H}_L^\tau \boldsymbol{\Lambda}_L \mathbf{H}_L) \hat{\boldsymbol{\theta}}_{\text{WLS}} = \mathbf{H}_L^\tau \boldsymbol{\Lambda}_L \mathbf{z}_L$$

上式称作正则方程。

3 最小二乘问题的解

当 $\mathbf{H}_L^T \mathbf{\Lambda}_L \mathbf{H}_L$ 是正则矩阵时，有

$$\hat{\boldsymbol{\theta}}_{\text{WLS}} = (\mathbf{H}_L^T \mathbf{\Lambda}_L \mathbf{H}_L)^{-1} \mathbf{H}_L^T \mathbf{\Lambda}_L \mathbf{z}_L$$

另外

$$\left. \frac{\partial^2 J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^2} \right|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} = 2 \mathbf{H}_L^T \mathbf{\Lambda}_L \mathbf{H}_L$$

因为 $\mathbf{\Lambda}_L$ 是正定矩阵，所以 $\mathbf{H}_L^T \mathbf{\Lambda}_L \mathbf{H}_L$ 也是正定矩阵，即

$$\left. \frac{\partial^2 J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^2} \right|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} > 0$$

所以 $\hat{\boldsymbol{\theta}}_{\text{WLS}}$ 使 $J(\boldsymbol{\theta})|_{\hat{\boldsymbol{\theta}}_{\text{WLS}}} = \min$ ，并且 $\hat{\boldsymbol{\theta}}_{\text{WLS}}$ 是唯一的。

3 最小二乘问题的解

当 $H_L^T \Lambda_L H_L$ 是正则矩阵时，模型的加权最小二乘解为

$$\hat{\theta}_{\text{WLS}} = (H_L^T \Lambda_L H_L)^{-1} H_L^T \Lambda_L z_L$$

● 通过极小化准则函数 $J(\theta)$ 求得模型参数估计值 $\hat{\theta}_{\text{WLS}}$ 的方法称作加权最小二乘法，记作WLS(Weighted Least Squares algorithm)，对应的 $\hat{\theta}_{\text{WLS}}$ 称为加权最小二乘估计值。

3 最小二乘问题的解

- 如果加权矩阵取单位阵，即 $\Lambda_L = I$ ，则加权最小二乘解退化成普通最小二乘解

$$\hat{\theta}_{LS} = (H_L^T H_L)^{-1} H_L^T z_L$$

- 这时的 $\hat{\theta}_{LS}$ 称之为最小二乘估计值，对应的估计方法称作最小二乘法，记作LS(Least Squares algorithm)。最小二乘法是加权最小二乘法的一种特例。

4 最小二乘估计的可辨识性

- 最小二乘估计的可辨识条件为： $2\mathbf{H}_L^T \Lambda_L \mathbf{H}_L$ 矩阵必须是非奇异的。
- 这一要求与数据集是“提供信息”的或辨识输入信号是“持续激励”的概念密切相关。

4 最小二乘估计的可辨识性

定理： 设输入信号 $u(k)$ 是拟平稳随机信号，如果相关函数矩阵

$$\mathbf{R}_u^n = \begin{bmatrix} R_u(0) & R_u(1) & \cdots & R_u(n-1) \\ \vdots & \vdots & \cdots & \vdots \\ R_u(n-1) & R_u(n-2) & \cdots & R_u(0) \end{bmatrix}$$

是非奇异的，则输入信号 $u(k)$ 是 n 阶持“持续激励”信号。

4 最小二乘估计的可辨识性

- 定理：当过程模型 $G(z^{-1})$ 为有理函数时，即

$$G(z^{-1}) = \frac{b_1 z^{-1} + b_2 z^{-2} + \cdots + b_{n_b} z^{-n_b}}{1 + a_1 z^{-1} + a_2 z^{-2} + \cdots + a_{n_a} z^{-n_a}}$$

- 则输入 $u(k)$ 为 $n_a + n_b$ 阶“持续激励”信号的辨识实验是“信息充足”的。

4 最小二乘估计的可辨识性

- 推论：为保证矩阵 $2\mathbf{H}_L^T \Lambda_L \mathbf{H}_L$ 是非奇异的，或者说使最小二乘估计是开环可辨识的，其充分必要条件是输入信号 $u(k)$ 必须是 $2n(n = \max(n_a, n_b))$ 阶“持续激励”信号。

4 最小二乘估计的可辨识性

- 则最小二乘估计的开环可辨识性条件，可写成

$$\mathbf{R}_u^{2n} > 0 \text{ or } \bar{\mathbf{U}}_L^T \bar{\mathbf{U}}_L > 0$$

- 式中相关函数矩阵 $\mathbf{R}_u^{2n}$ 按如下构成，

$$\mathbf{R}_u^n = \begin{bmatrix} R_u(0) & R_u(1) & \cdots & R_u(n-1) \\ \vdots & \vdots & \cdots & \vdots \\ R_u(n-1) & R_u(n-2) & \cdots & R_u(0) \end{bmatrix}$$

4 最小二乘估计的可辨识性

- 矩阵 $\bar{\mathbf{U}}_L$ 按下式组成

$$\left\{ \begin{array}{l} \bar{\mathbf{U}}_L = [\mathbf{F}\mathbf{u}_L \quad \mathbf{F}^2\mathbf{u}_L \quad \cdots \quad \mathbf{F}^{2n}\mathbf{u}_L] \\ \mathbf{u}_L = [u(1) \quad u(2) \quad \cdots \quad u(L)] \\ \mathbf{F} = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 1 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 1 & 0 \end{bmatrix}_{L \times L} \\ n = \max(n_a, n_b) \end{array} \right.$$

4 最小二乘估计的可辨识性

- 上述条件称作开环可辨识性条件。辨识所用的输入信号不能随意选择，否则可能造成不可辨识。
- 常用输入信号包括：
 - 随机序列（如白噪声）；
 - 伪随机序列（如M序列或逆M序列）；
 - 离散序列，通常指对含有 n 种频率的正弦组合信号进行采样处理获得的离散序列。

4 最小二乘估计的可辨识性

- 例1 过程脉冲响应的辨识

设线性过程的输出 $z(k)$ 用输入序列 $\{u(k)\}$ 与脉冲响应序列 $\{g(i)\}, i=0,1,\dots,N$ 的卷积和形式表示

$$z(k) = \sum_{i=0}^N g(i)u(k-i) + w(k)$$

其中， $w(k)$ 是过程输出测量噪声，假设是零均值白噪声。

4 最小二乘估计的可辨识性

当取 $k=1,2,\cdots,L$ 时, 上式可写成如下形式

$$\mathbf{z}_L = \mathbf{H}_L \mathbf{g} + \mathbf{w}_L$$

其中

$$\begin{cases} \mathbf{z}_L = [z(1), z(2), \cdots, z(L)]^T \\ \mathbf{g} = [g(1), g(2), \cdots, g(N)]^T \\ \mathbf{w}_L = [w(1), w(2), \cdots, w(L)]^T \\ \mathbf{H}_L = \begin{bmatrix} u(1) & u(0) & u(1-N) \\ u(2) & u(1) & u(2-N) \\ \vdots & \vdots & \vdots \\ u(L) & u(L-1) & u(L-N) \end{bmatrix} \end{cases}$$

$\mathbf{z}_L$ 和 $\mathbf{H}_L$ 都是可测数据。根据最小二乘解公式, 过程脉冲响应的最小二乘估计值为

$$\hat{\mathbf{g}}_{LS} = (\mathbf{H}_L^T \mathbf{H}_L)^{-1} \mathbf{H}_L^T \mathbf{z}_L$$

4 最小二乘估计的可辨识性

- 例2 考虑如下仿真对象

$$z(k) - 1.5z(k-1) + 0.7z(k-2) = u(k-1) + 0.5u(k-2) + v(k)$$

其中， $v(k)$ 为服从 $N(0,1)$ 分布的白噪声。输入信号采用4阶M序列，幅度为1。选择如下的辨识模型。

$$z(k) + a_1z(k-1) + a_2z(k-2) = b_1u(k-1) + b_2u(k-2) + v(k)$$

构造数据向量 $\mathbf{z}_L$ 和矩阵 $\mathbf{H}_L$ ；数据长度选择为 $L=400$ ；加权阵取单位阵，利用最小二乘参数估计，得到结果。

4 最小二乘估计的可辨识性

参数	a_1	a_2	b_1	b_2
真值	-1.5	0.7	1.0	0.5
估计值	-1.520	0.720	0.946	0.566